

RECONOCIMIENTO DE LENGUA DE SEÑAS ARGENTINA (LSA64)

Sistema de Inferencia en Tiempo Real con BiLSTM + MediaPipe

Traducción automática de gestos a texto y voz

64 Clases · 82% Precisión · Tiempo Real

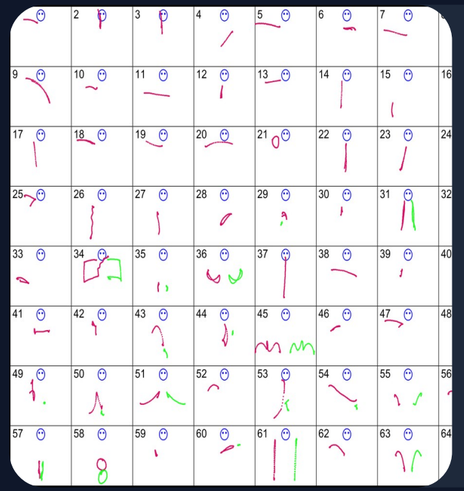
CONTENIDOS

Estructura de la Presentación



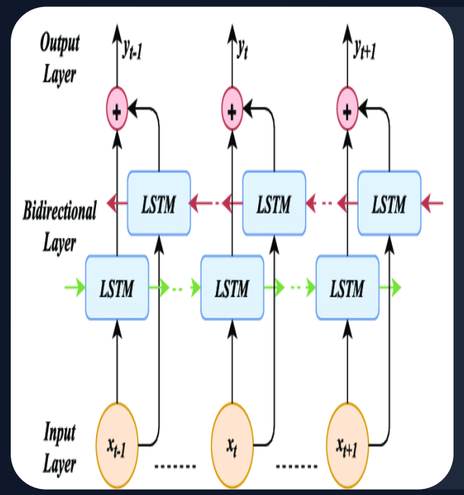
01
Introducción

El proyecto, la problemática de la comunidad sorda y el impacto social



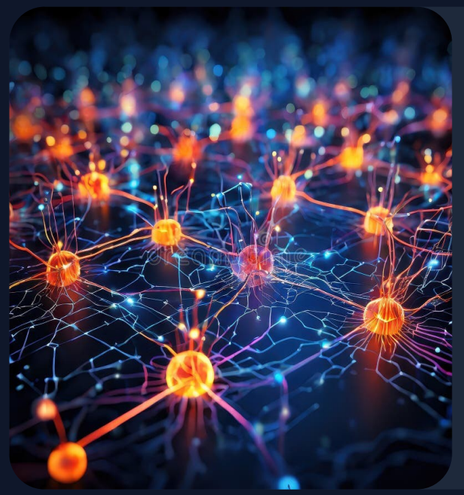
02
Estado del Arte

Antecedentes, tecnologías relacionadas y el dataset LSA64



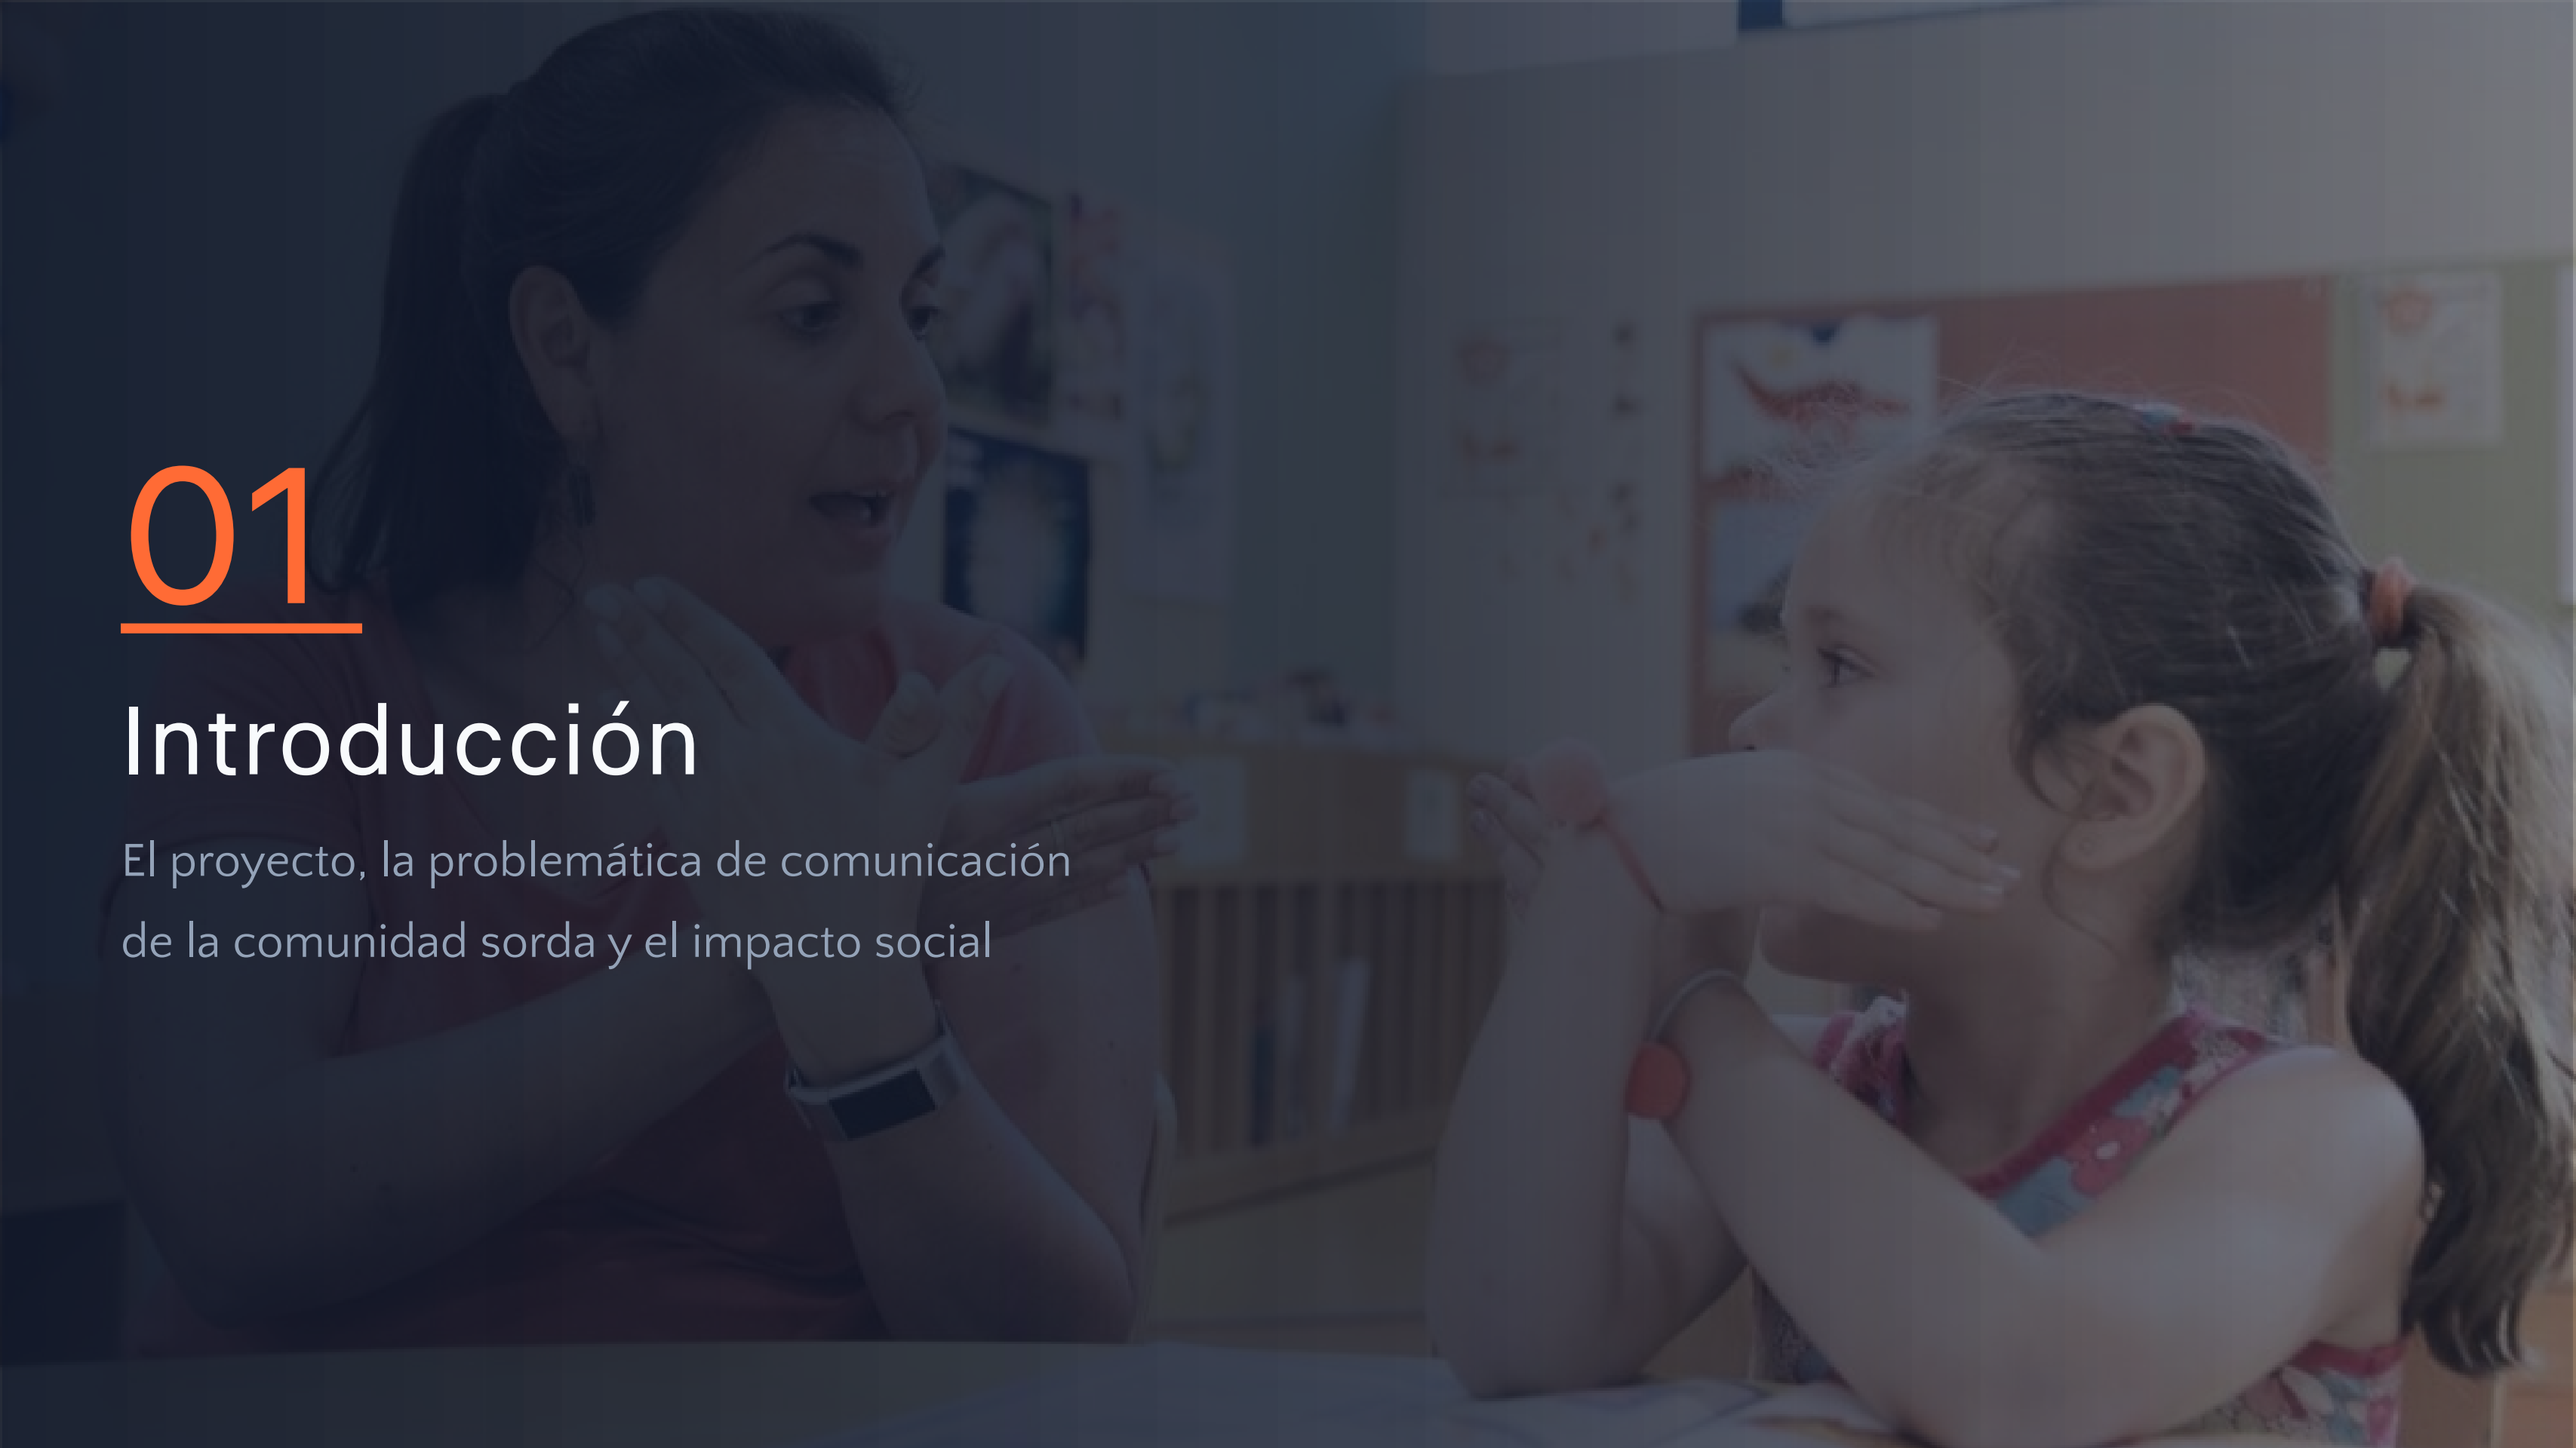
03
Metodología

Arquitectura del sistema, pipeline de procesamiento y estrategia de entrenamiento



04
Resultados

Métricas de evaluación, análisis de rendimiento y conclusiones del proyecto



01

Introducción

El proyecto, la problemática de comunicación de la comunidad sorda y el impacto social



PROBLEMÁTICA

La Barrera de Comunicación

Aproximadamente **70 millones** de personas en el mundo tienen discapacidad auditiva severa.

La **Lengua de Señas Argentina (LSA)** es la lengua natural de la comunidad sorda argentina, pero la brecha comunicacional limita su acceso a:

- Educación
- Salud
- Empleo
- Inclusión social

Este proyecto busca crear un **puente tecnológico** entre el mundo auditivo y la comunidad sorda mediante Inteligencia Artificial.

70M+

Personas sordas

INTRODUCCIÓN

Objetivos del Proyecto

Reconocimiento en Tiempo Real

Desarrollar un sistema de reconocimiento de LSA64 usando BiLSTM con inferencia en vivo

64 Clases de Señas

Reconocer 64 clases de señas argentinas con alta precisión y traducción al español

Texto y Voz en Español

Proporcionar traducción a texto y voz en español mediante Google TTS

Interfaz Profesional

Crear una interfaz gráfica premium y responsiva con Dark Theme estilo Dashboard

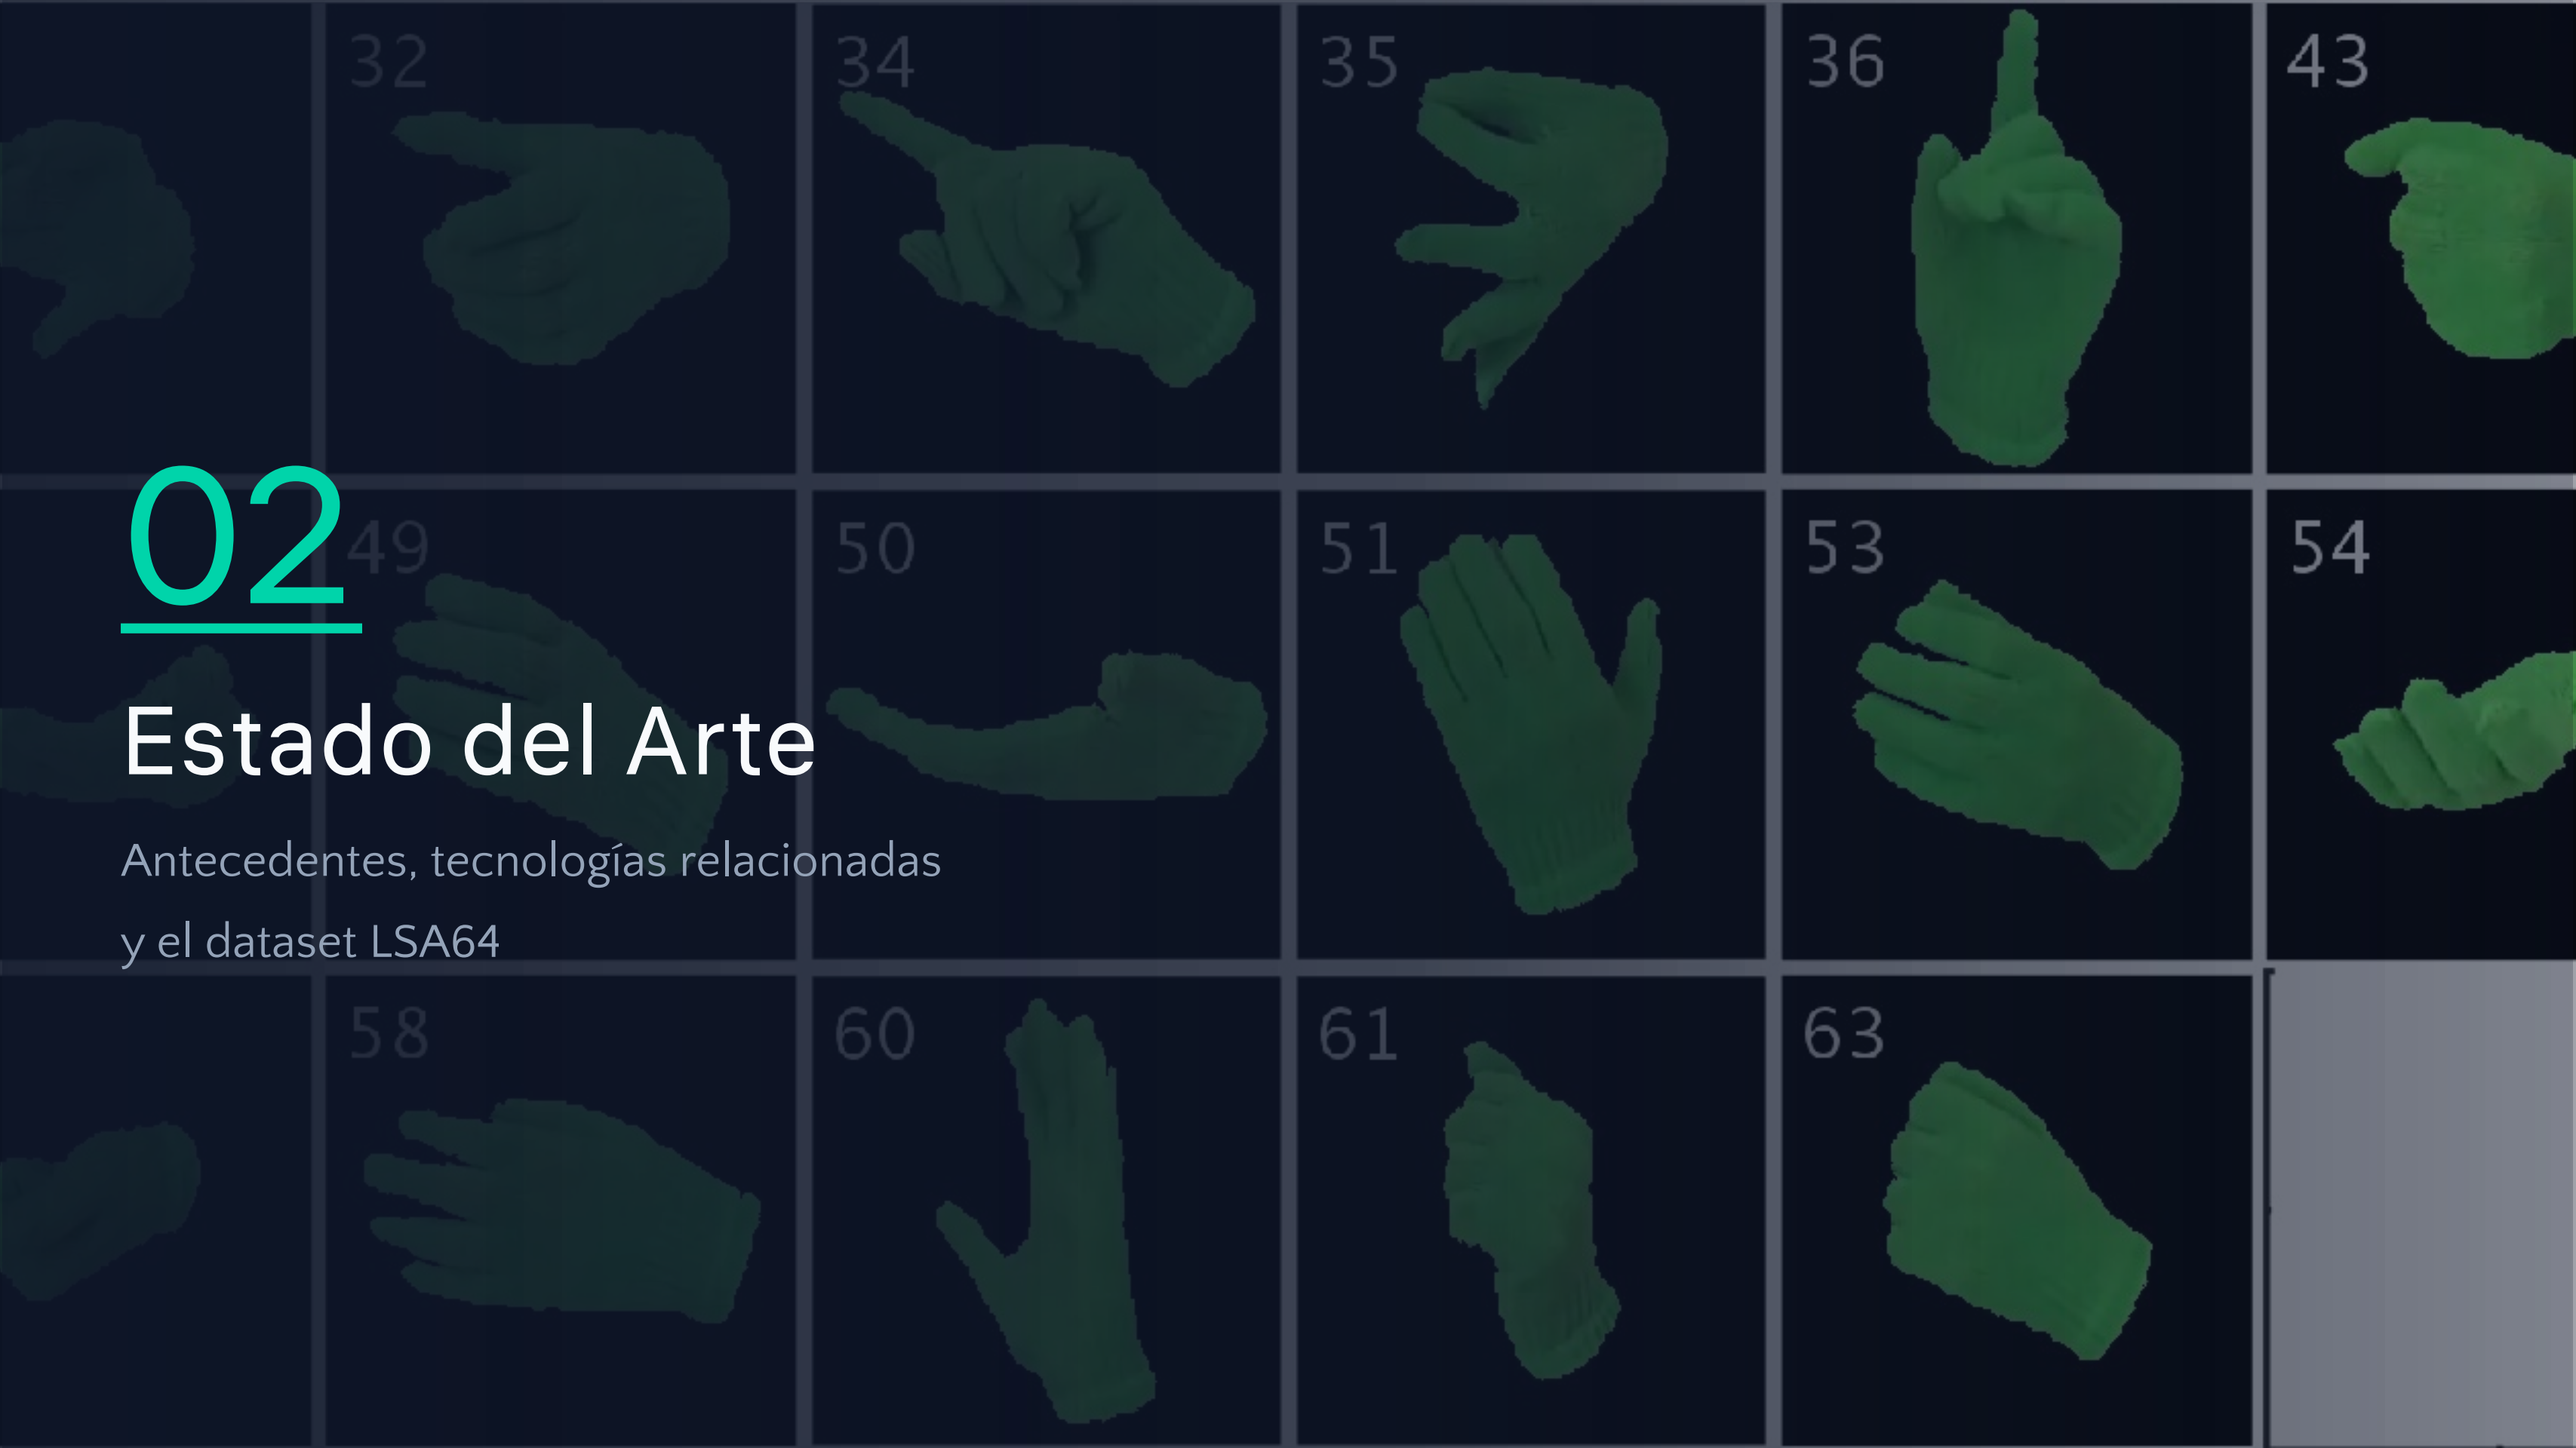
Portabilidad Total

Empaquetar el sistema en formato portable listo para desplegar en cualquier PC

Alta Fidelidad

Alinear con estándares de alta fidelidad de sistemas de monitoreo biométrico





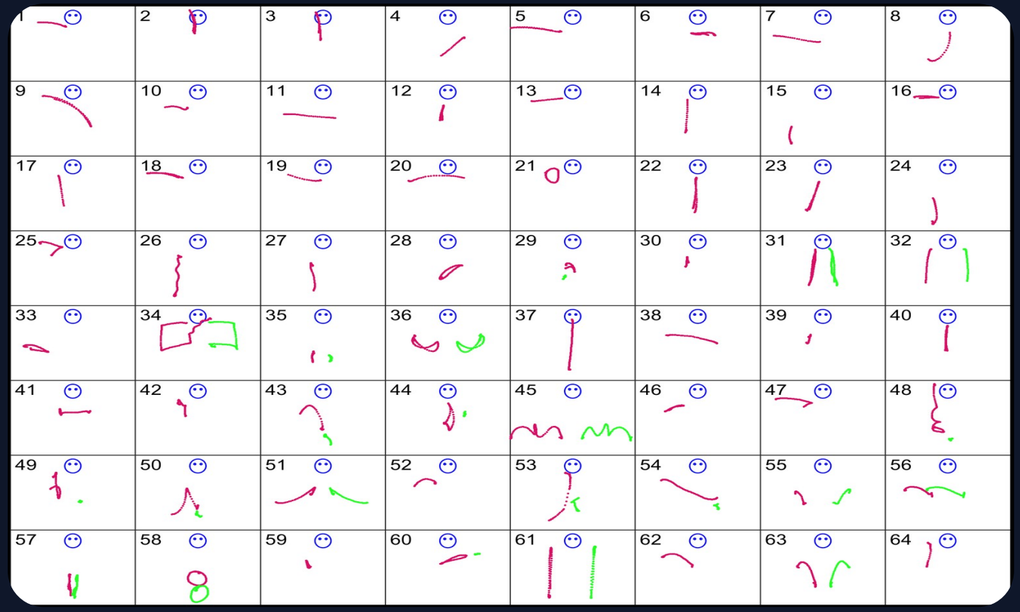
02

Estado del Arte

Antecedentes, tecnologías relacionadas y el dataset LSA64

ESTADO DEL ARTE

Dataset LSA64



Visualización de las 64 clases de señas del dataset LSA64

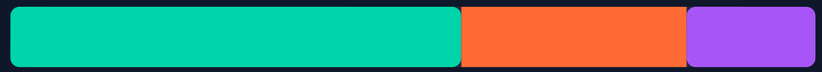


64	10	5	3.2K
Clases de señas	Sujetos	Repeticiones	Videos

Características del Dataset

- Creado por **Facundo Quiroga** - referente en LSA
- Formato: **CCC_SSS_RRR.mp4** (Clase/Sujeto/Repetición)
- Split subject-independent para evitar data leakage
- Clases: colores, personas, alimentos, verbos, lugares

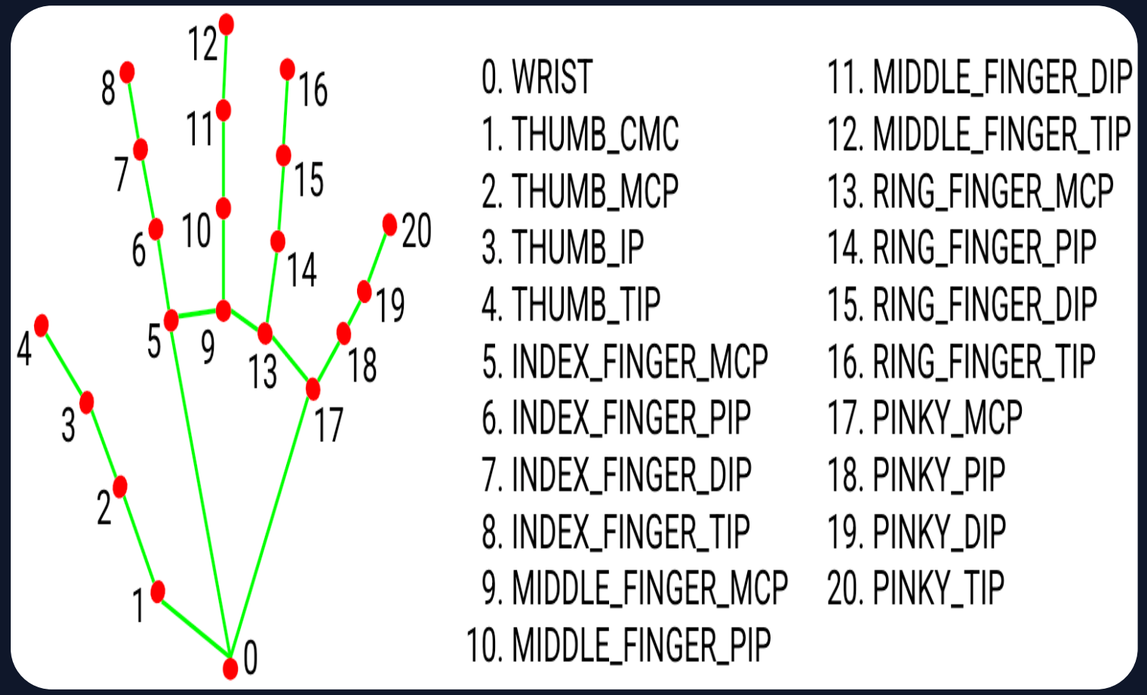
División del Dataset



Train 70% (Sujetos 1-7) Val 20% (Sujetos 8-9) Test 10% (Sujeto 10)

ESTADO DEL ARTE

MediaPipe Hands



0. WRIST
1. THUMB_CMC
2. THUMB_MCP
3. THUMB_IP
4. THUMB_TIP
5. INDEX_FINGER_MCP
6. INDEX_FINGER_PIP
7. INDEX_FINGER_DIP
8. INDEX_FINGER_TIP
9. MIDDLE_FINGER_MCP
10. MIDDLE_FINGER_PIP
11. MIDDLE_FINGER_DIP
12. MIDDLE_FINGER_TIP
13. RING_FINGER_MCP
14. RING_FINGER_PIP
15. RING_FINGER_DIP
16. RING_FINGER_TIP
17. PINKY_MCP
18. PINKY_PIP
19. PINKY_DIP
20. PINKY_TIP

21 landmarks por mano = 42 puntos de referencia en total (x, y, z)

21 Puntos por Mano

42 puntos en total con coordenadas (x, y, z) en pixeles 3D

Tiempo Real

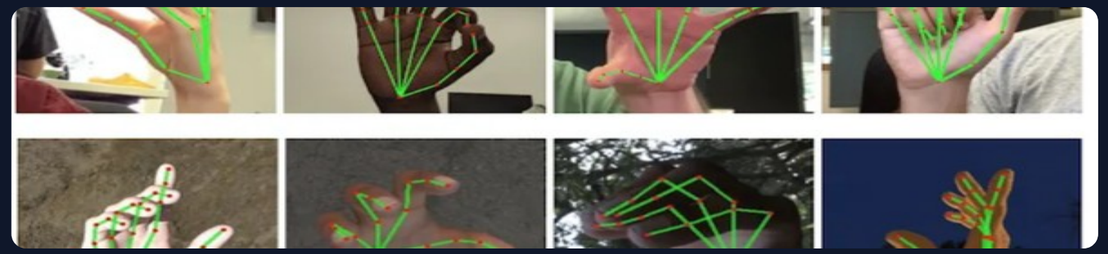
Detección optimizada para CPU y GPU sin latencia perceptible

Robustez

Procesamiento en diferentes condiciones de iluminación y fondo

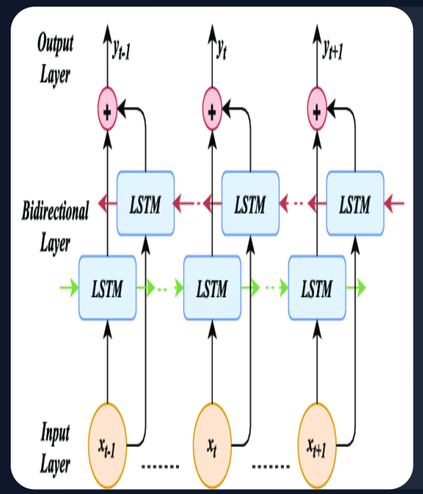
Geometría 3D Completa

Extracción de coordenadas 3D para capturar la forma completa de los dedos



ESTADO DEL ARTE

Tecnologías Relacionadas



BiLSTM

Captura dependencias temporales en ambas direcciones del tiempo, ideal para secuencias de gestos

Arquitectura

Transfer Learning

Backbone pre-entrenado en dataset AUTSL para aprovechar conocimiento previo del movimiento de manos

Estrategia

Focal Loss

Penaliza errores en clases difíciles y desbalanceadas del dataset

Google TTS

Conversión de texto a voz en español con reproducción asíncrona

Procesamiento Paralelo

Extracción multihilo y TTS en hilos secundarios sin congelar FPS



03

Metodología

Arquitectura del sistema, pipeline de procesamiento y estrategia de entrenamiento

METODOLOGÍA

Evolución de la Arquitectura

FASE A

177D

Enfoque Multimodelo

YOLO Pose + MediaPipe combinados. Esqueleto corporal + manos. Lento, redundante y propenso a errores de GPU.

Descartado

FASE B

126D

Hand-Centric

Solo manos: 42 puntos × 3 ejes = 126 dims. Coordenadas en píxeles 3D. Mejoró la comprensión geométrica.

Base sólida

FASE C

130D

Consciencia Espacial

+4 dims de posición global de muñecas. Distingue gestos idénticos en frente vs pecho. Fix crítico que elevó la precisión radicalmente.

Final ✓

Insight Clave

La matriz de confusión reveló que aislar las manos destruía la "posición global". El modelo no podía distinguir gestos idénticos en diferentes ubicaciones del cuerpo. Las 4 dimensiones extra de posición relativa restauraron la consciencia espacial.

METODOLOGÍA

Arquitectura BiLSTM

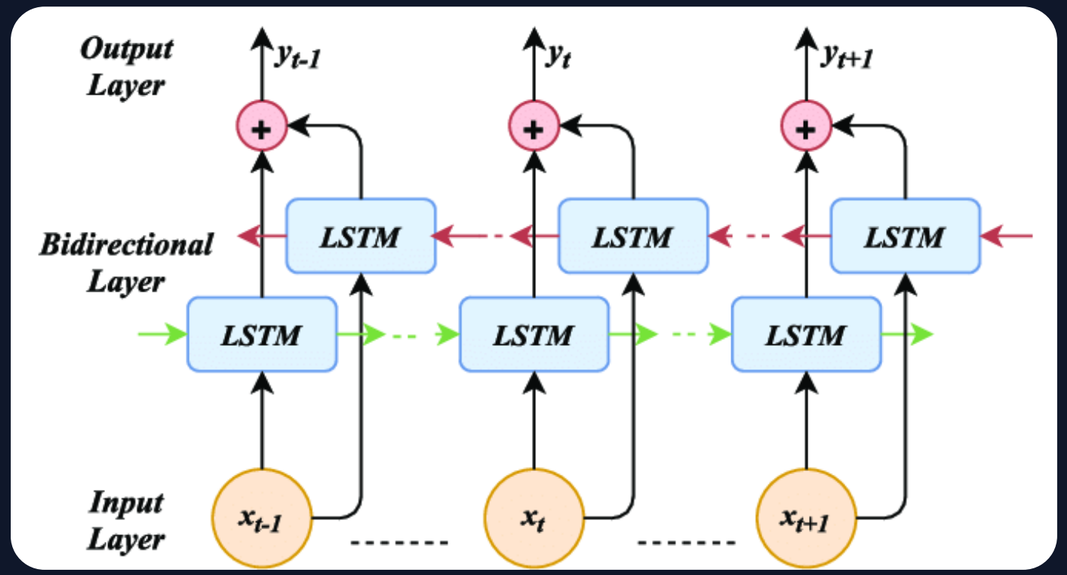


Diagrama de una red BiLSTM bidireccional

Input: Secuencias de max 64 frames (Batch × 64 × 130)

Proyección: Linear + LayerNorm + ReLU + Dropout

BiLSTM: 2 capas, dropout manual post-LSTM

Attention: Pooling temporal ponderando frames relevantes

Head: Linear + ReLU + Dropout → 64 clases

Transfer Learning

El entrenamiento se inició sobre un backbone pre-entrenado con el dataset AUTSL, transfiriendo el entendimiento físico del movimiento antes de afinar para LSA64.

AUTSL
Pre-entrenamiento

LSA64
Fine-tuning

Congelar backbone → Reemplazar head → Entrenar completo

METODOLOGÍA

Pipeline de Preprocesamiento

Bug Crítico de Normalización

La función de centrado usaba el eje Z (profundidad) como "confianza". Los dedos apuntando a la cámara tienen profundidad negativa, borrando **20 de 21 puntos**.

✓ Corrección: Máscara que evalúa X e Y, salvando la integridad de los datos.

Optimización Multihilo

Extractor rediseñado para procesamiento en paralelo puro en CPU, evitando clashes de OpenGL/EGL.

✓ Resultado: Extracción de **3,200 videos** en solo **~34 minutos** sin errores.

Pipeline de Procesamiento



Focal Loss para penalizar errores en clases difíciles · Pack Padded Sequences para eficiencia · Secuencias de 130 dims



04

Resultados y Conclusiones

Métricas de evaluación, análisis de rendimiento e inferencia en tiempo real

RESULTADOS

El Salto de Precisión

ANTES

62.6%
Precision de Validación

51.2%
Precision de Test

5 / 64

Gestos perfectos

DESPUÉS

91.1%
Precision de Validación

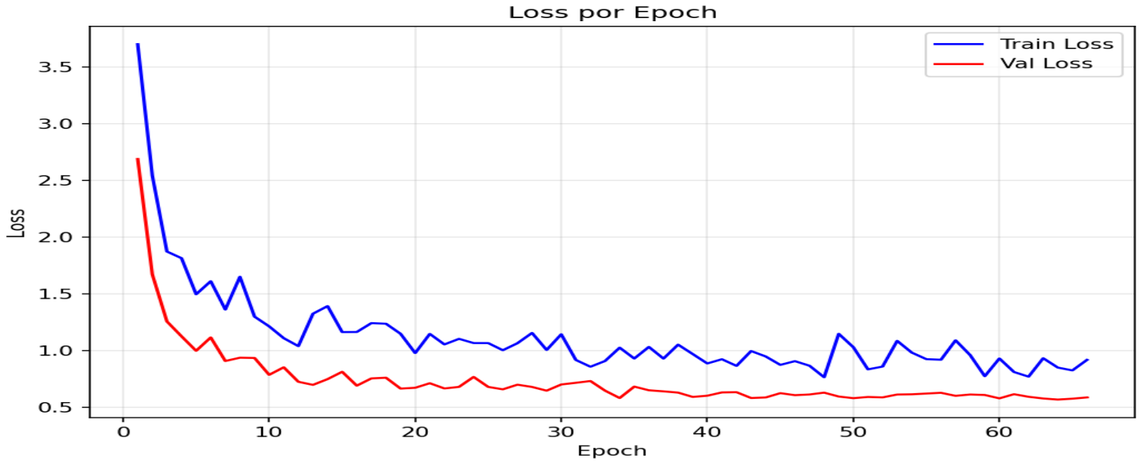
+28.5

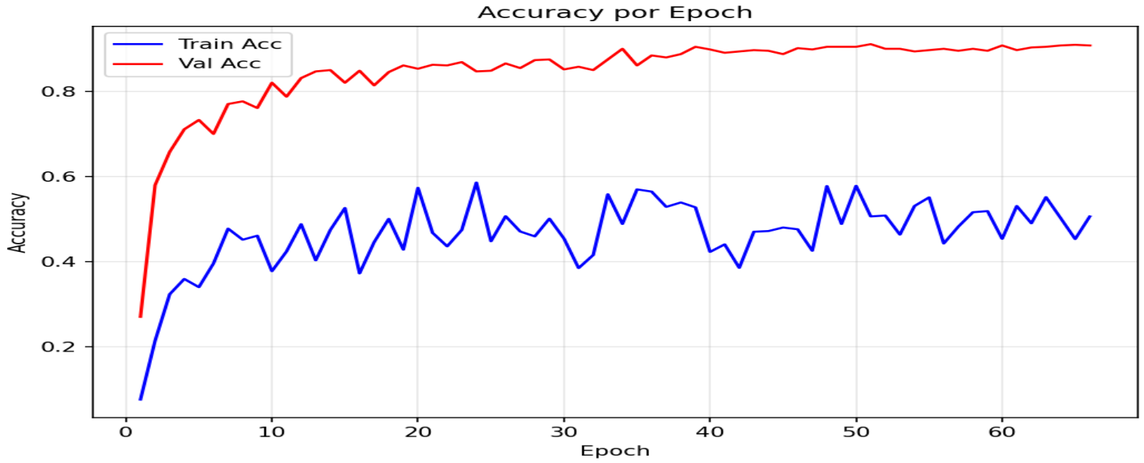
82.0%
Precision de Test +30.8

31 / 64

Gestos perfectos (48%)

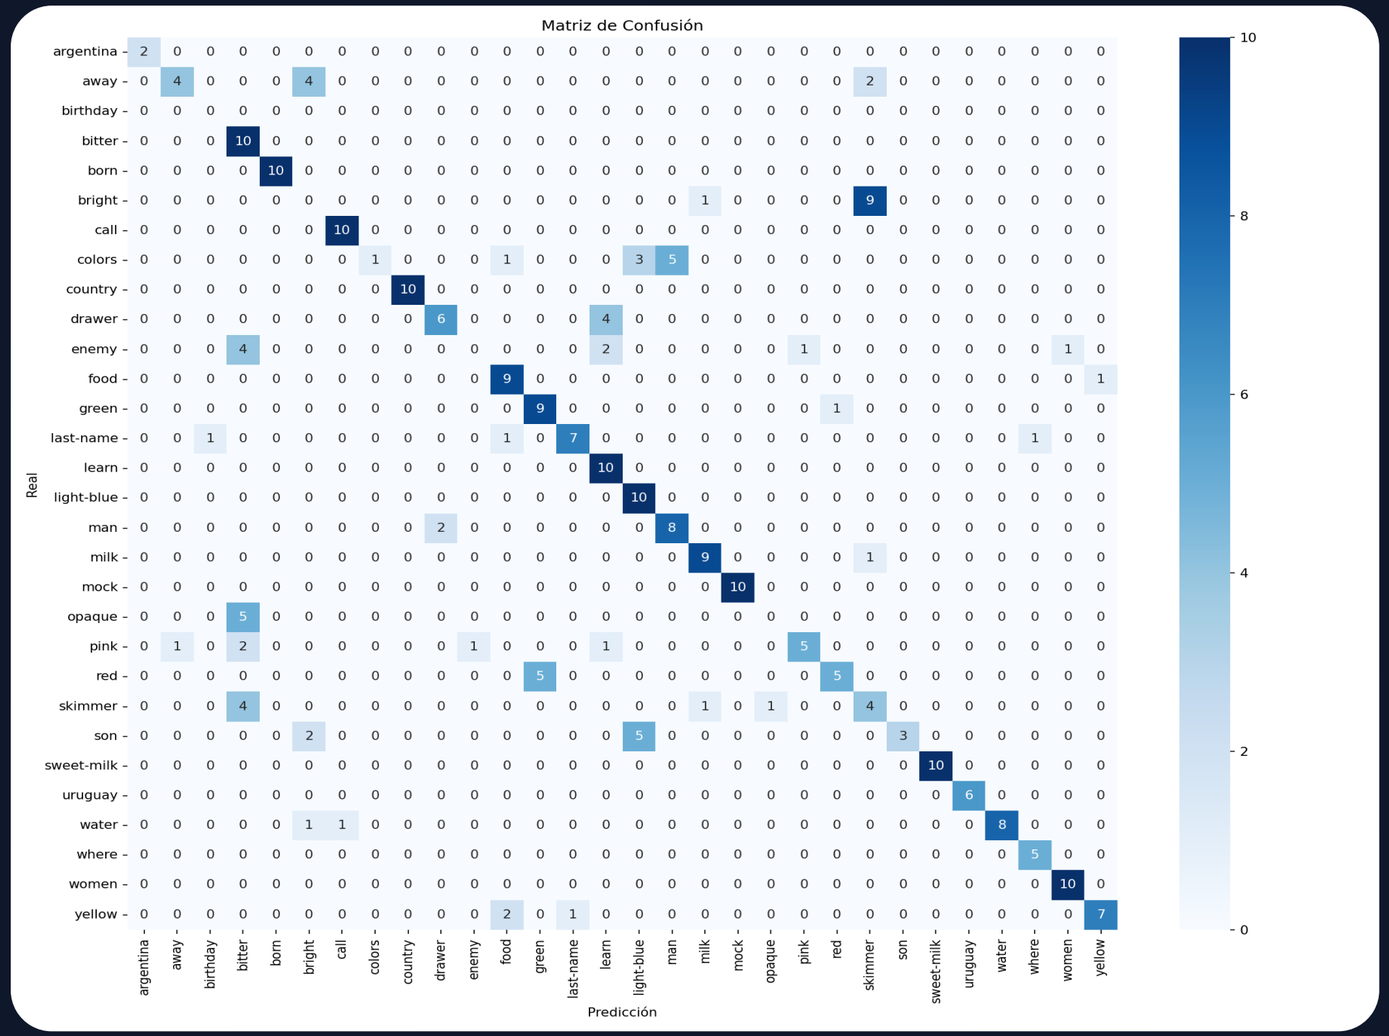
Curvas de Entrenamiento





RESULTADOS

Matriz de Confusión



Clases con Precisión Perfecta

- born, learn, call, bitter, sweet-milk
- country, mock, hungry, map, coin
- ship, none, trap, rice, yogurt
- help, copy, women, light-blue
- **17 clases con 100% accuracy**

Clases con Mayor Dificultad

- opaque, bright, enemy, birthday
- deaf, candy, accept, colors
- **6 clases con 0% accuracy**

Macro Avg F1	Top-5 Accuracy
0.611	92.8%

RESULTADOS

Inferencia en Vivo



Interfaz Dark Theme Premium

Panel lateral estilo Dashboard con nodos de manos en escala de píxeles reales

Traducción Nativa al Español

64 clases mapeadas del inglés al español (ej: sweet-milk → dulce de leche)

Motor de Voz Asíncrono (gTTS)

Google TTS en hilo separado, dicta en español sin congelar los FPS de cámara

Portabilidad Total

Sistema empaquetado en .tar.gz listo para desplegar en cualquier PC con Python

CONCLUSIONES

Conclusiones

Evolución Radical

De un modelo ruidoso con múltiples dependencias a una arquitectura BiLSTM matemática y espacialmente consciente

Calidad > Complejidad

La calidad geométrica de los datos es más importante que la complejidad bruta de la red neuronal

Ingeniería de Precisión

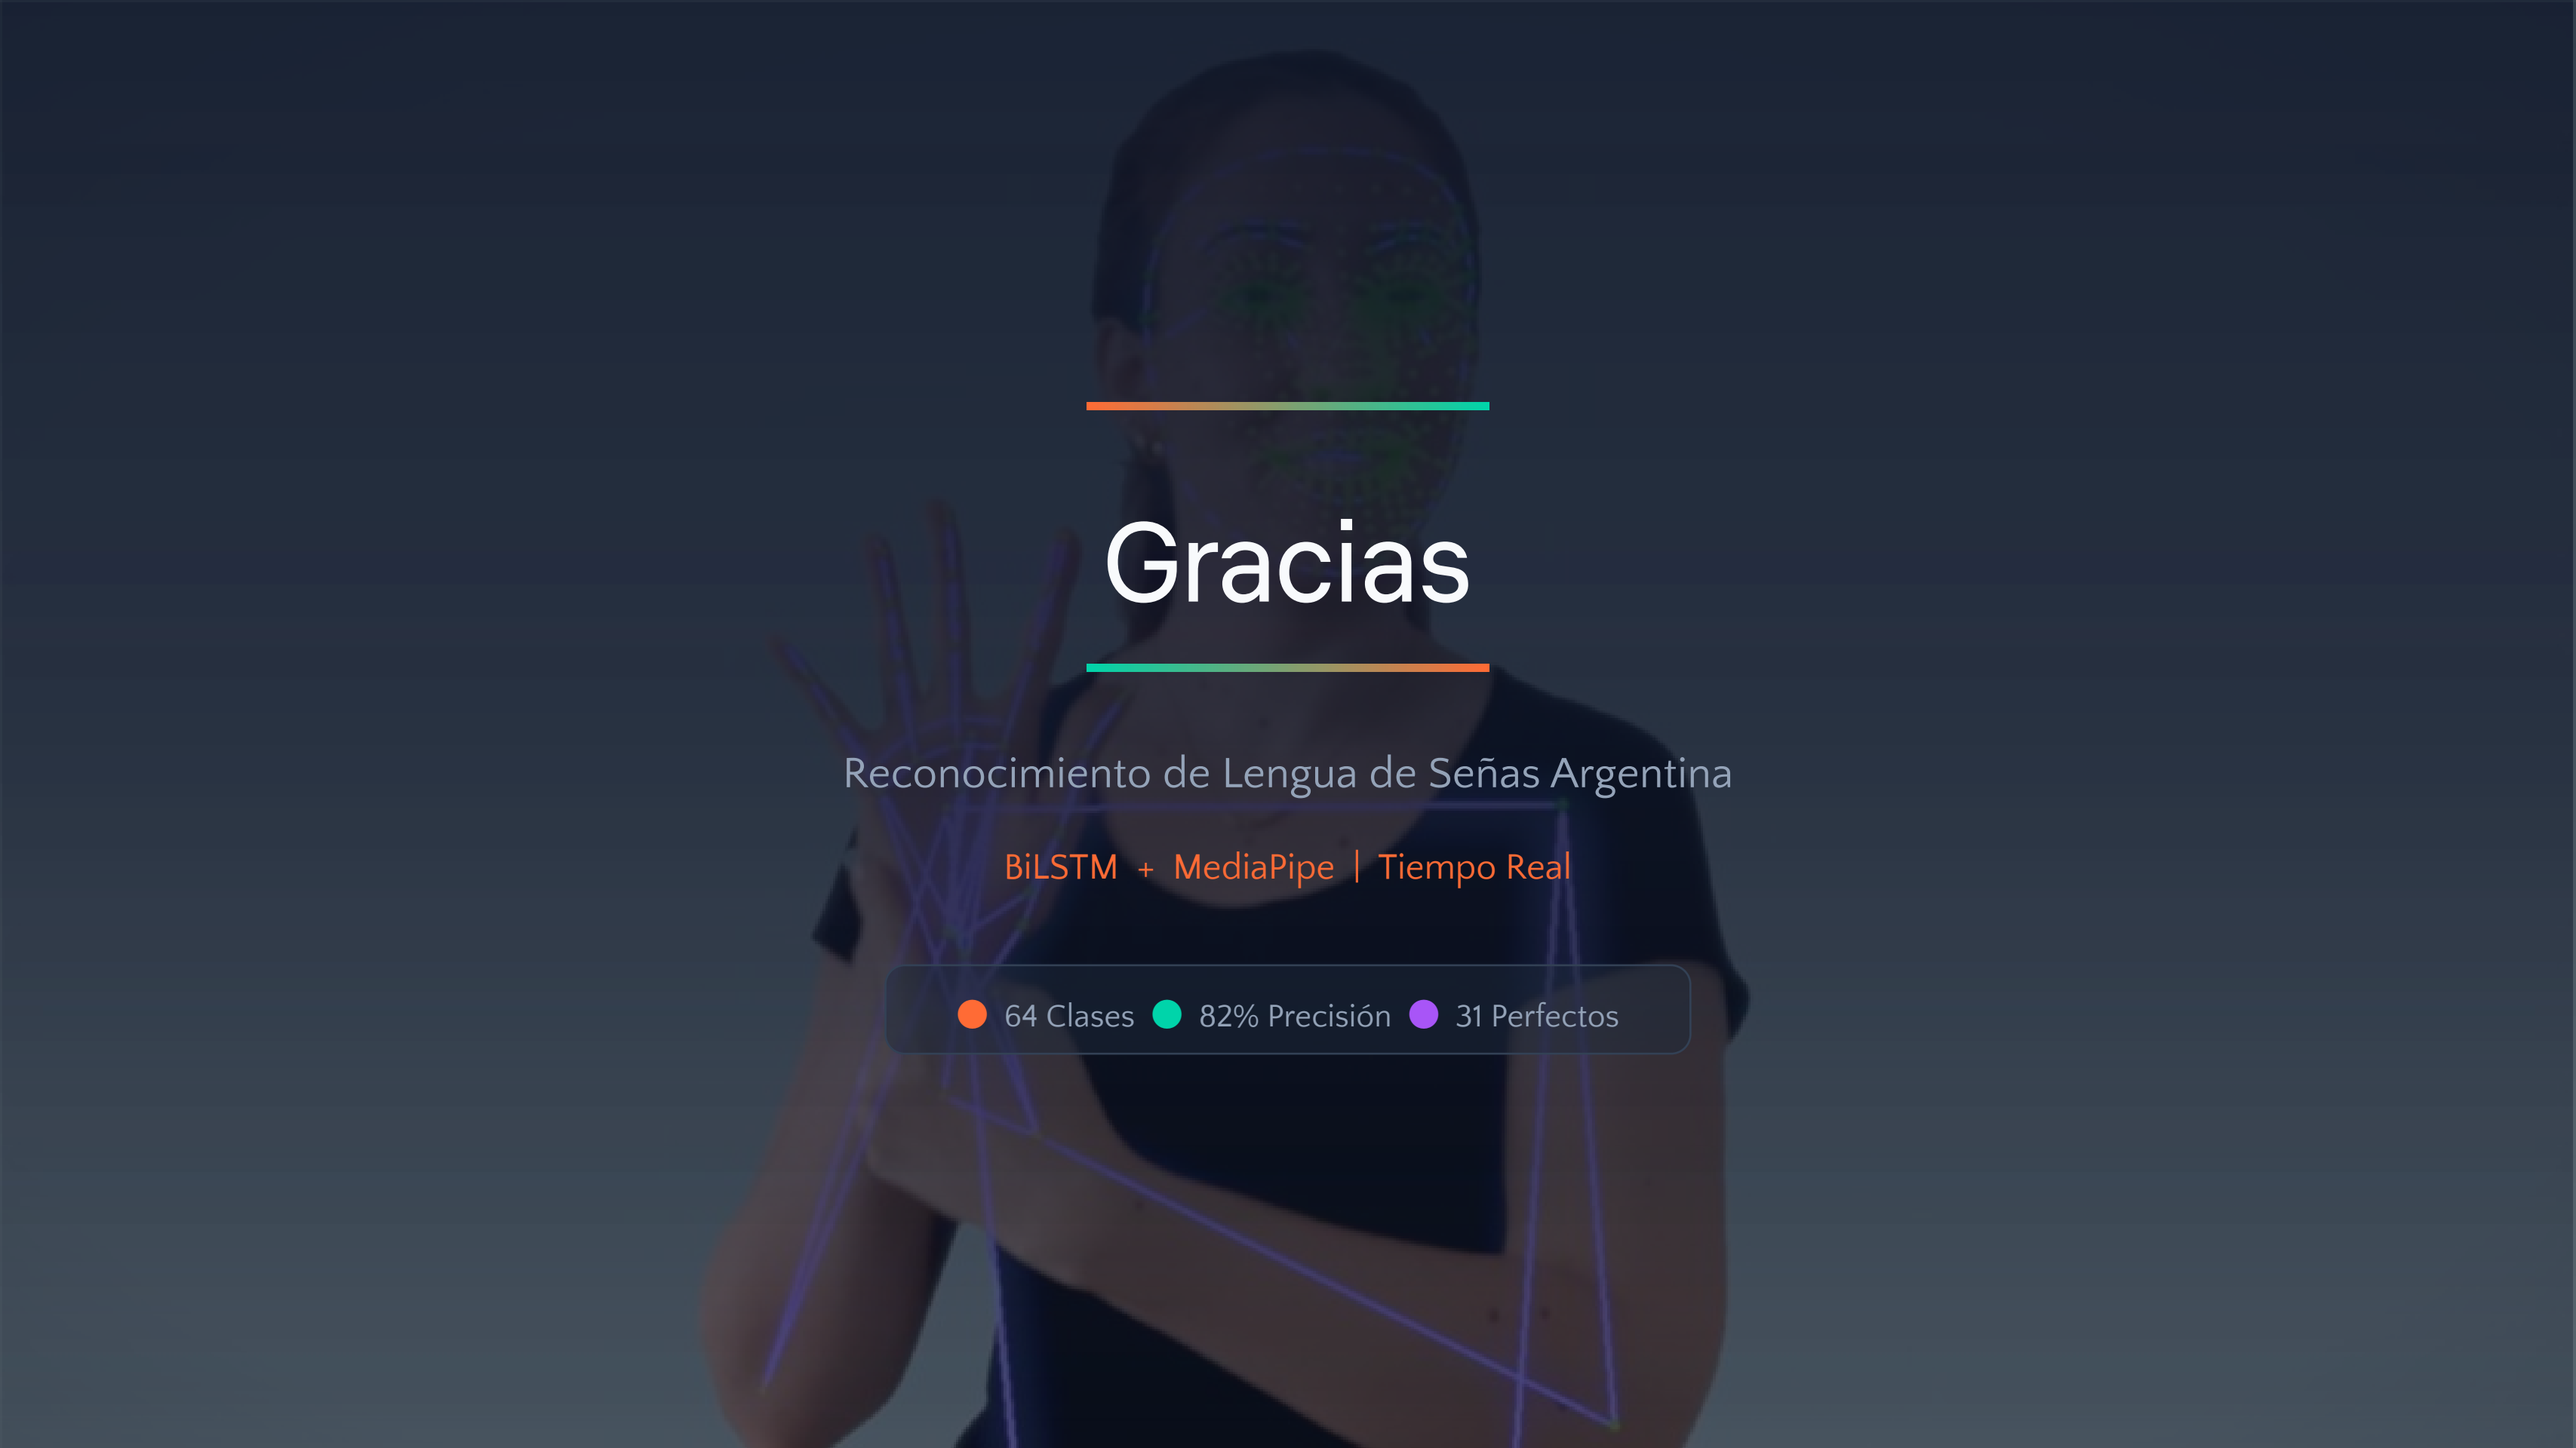
Decisiones clave: 130 dims, TTS en hilos, normalización 3D corregida. Cada decisión tuvo impacto medible

Resultados Concretos

31 de 64 gestos reconocidos perfectamente. 82% de precisión en test real. Top-5 accuracy del 92.8%

Trabajo Futuro

- Expandir el vocabulario más allá de las 64 clases actuales
- Mejorar reconocimiento de las clases más difíciles
- Integración con sistemas de Realidad Aumentada
- Soporte para frases completas y contexto gramatical



Gracias

Reconocimiento de Lengua de Señas Argentina

BiLSTM + MediaPipe | Tiempo Real

64 Clases · 82% Precisión · 31 Perfectos